

Informe: Similitud del Coseno

Modelos de Clasificación — Técnicas para el Análisis de Textos

Implementación con TF-IDF y similitud del coseno en Python

1. Descripción del Código

El script implementa un flujo de análisis de similitud semántica entre documentos de texto, utilizando la representación TF-IDF y la métrica de similitud del coseno. A continuación se describen las bibliotecas utilizadas y su rol en el proceso:

Bibliotecas y Dependencias	
numpy	Soporte de operaciones matriciales y numéricas
seaborn	Visualización del heatmap de la matriz de similitud
matplotlib	Renderizado y configuración de la figura
sklearn — TfidfVectorizer	Conversión de textos a vectores TF-IDF
sklearn — cosine_similarity	Cálculo de la similitud del coseno entre vectores

2. Documentos de Entrada

Se utilizaron tres documentos breves en español, todos relacionados temáticamente con animales domésticos:

Documento	Contenido
doc1	"El veloz zorro marrón salta sobre el perro perezoso."
doc2	"Un perro marrón persiguió al zorro."
doc3	"El perro es perezoso."

3. Metodología

3.1 Vectorización TF-IDF

Los textos son convertidos a vectores numéricos mediante `TfidfVectorizer` de `scikit-learn`. TF-IDF (Term Frequency — Inverse Document Frequency) pondera cada término según su frecuencia en el documento y su rareza en el corpus, produciendo representaciones que capturan la relevancia de cada palabra.

```
vectorizer = TfidfVectorizer()
tfidf_matrix = vectorizer.fit_transform(documents.values())
```

3.2 Similitud del Coseno

La similitud del coseno mide el ángulo entre dos vectores en el espacio TF-IDF. Un valor de 1.0 indica que los documentos son idénticos en términos de contenido; un valor cercano a 0 indica que no comparten vocabulario relevante.

La fórmula utilizada es:

$$\text{similitud}(A, B) = (A \cdot B) / (||A|| \times ||B||)$$

4. Resultados — Matriz de Similitud del Coseno

La siguiente tabla muestra los valores de similitud calculados entre cada par de documentos:

	doc1	doc2	doc3
doc1	1.00	0.26	0.48
doc2	0.26	1.00	0.10
doc3	0.48	0.10	1.00

4.1 Visualización — Heatmap

El heatmap generado por `seaborn` permite observar visualmente la intensidad de la similitud entre cada par de documentos. Las celdas más oscuras indican mayor similitud:




Figura 1. Heatmap de la Matriz de Similitud del Coseno — generado con seaborn y matplotlib

5. Interpretación de los Resultados

- **doc1 ↔ doc2 (0.26):** Similitud baja. Comparten los términos "perro", "marrón" y "zorro", pero doc1 tiene mayor vocabulario específico.
- **doc1 ↔ doc3 (0.48):** Similitud moderada. Ambos documentos mencionan "perro" y "perezoso", palabras de mayor peso TF-IDF en el corpus.
- **doc2 ↔ doc3 (0.10):** Similitud muy baja. Comparten únicamente "perro", con poco vocabulario en común.

Los valores de la diagonal principal siempre son 1.00, ya que cada documento es idéntico a sí mismo. Este comportamiento es esperado y confirma el correcto funcionamiento del algoritmo.